

LEC. 5

ملخص:

1. MLPs المشكلة في الـ CNN؟ليه أصلاً اخترعوا الـ

- Fully Connected MLP) بيكسل وملونة (3 قنوات ألوان)، وحبينا ندخلها على شبكة عادية 400×400 لو عندنا صورة عادية حجمها 400 ، هنضطر نفرد الصورة دي لصف طويل (Connected MLP).
- مليون باراميتري (وزن) للطبقة دي بس! ده 240 تخيل إن أول طبقة بس فيها 500 نيورون، ده معناه إننا محتاجين رقم خرافي بيحتاج ميموري ضخمة وصعب جداً في التدريب.
- بتبدل فكرة إن "كل حاجة تتوصل بكل حاجة" بفكرة الفلاتر CNN الـ: الحل.

2. Convolution يعني إيه؟ (الالتفاف)

- أو 3×3 مثلاً حجمه 3 Kernel أو (Filter) بدل ما نوصل الصورة كلها ببعض، بنستخدم "مربع صغير" اسمه فلتر 5×5 .
- الفلتر ده بيمشي (يزحف) على الصورة حته حته، يضرب الأرقام اللي جواه في أرقام الصورة ويجمعهم، ويطلع Convolution. رقم واحد لكل منطقة. العملية دي اسمها
- ، خطوط بالطول، خطوط بالعرض، وهكذا (Edges) الفلاتر دي بتتلعن تطلع ميزات معينة، زي الحواف.

3. CNN أهم خواص الـ

- كل نيورون في الطبقة الجديدة ببص بس على حته صغيرة من (Sparse Interaction) التوصيل المحلي. الصورة الأصلية (على قد حجم الفلتر)، مش الصورة كلها.
- دي نقطة عبقرية. الفلتر اللي اتعلم شكل "العين" في أول الصورة، (Parameter Sharing) مشاركة الأوزان هو هو نفس الفلتر اللي هنمشيه على باقي الصورة عشان يدور على "عيون" ثانية. يعني بنستخدم نفس الأرقام للصورة كلها، وده بيقلل عدد الباراميتريز جداً (Weights).
- لو القطعة اللي في الصورة اتحركت يمين، النتيجة اللي هتطلع من الفلتر كمان (Equivariance) التكافؤ. هتتحرك يمين بنفس المقدار.

4. تفاصيل التشغيل (Strides & Padding)

- ، Stride=2 ولا بننط؟ لو عملنا (Stride=1) وإحنا بنحرك الفلتر، بنمشي مربع مربع (الخطوة) Stride.
- لما بنطبق الفلتر، حجم الصورة بيقل شوية من الجوانب. عشان نحافظ على الحجم، بنزود (الحشو) Padding. بروتاز من الأصفر حوالين الصورة، وده اسمه

5. التعامل مع الصور الملونة (3D Volumes)

- (قنوات 3) RGB اللي هو ألوان الـ (Depth) بس، دي ليها عمق D الصور الحقيقية مش 2.
- وعشان نطلع ميزات كتير، بنستخدم كذا فلتر. (3x5x5) مثلاً 5 هو كمان 3D عشان كده الفلتر بتاعنا لازم يكون (مثلاً 64 فلتر)، فالخرج بيكون حجمه عميق (مثلاً 64 قناة).

6. 1 Convolution الـ 1x1

- 1x1 ممكن تستغرب، إيه لازمة فلتر حجمه 1
- وظيفته الأساسية إنه يقلل عدد القنوات (Depth) الفلتر ده ببص على البكسل الواحد بس عبر كل قنوات الألوان (مثلاً من 192 قناة لـ 32 قناة) عشان يوفر حسابات ويخلي الموديل أخف، ودي طريقة رخيصة حسابياً

7. Pooling) طبقة التلخيص

- ، بنحتاج نصغر حجم الصورة عشان نركز على المهم ونقلل الحسابات Convolution بعد ما بنطلع الميزات بالـ
- ، وناخد أكبر رقم في كل مربع ونرمي الباقي. ده (2x2 مثلاً 2) أشهر نوع. بنقسم الصورة مربعات **Max Pooling** (Translation Invariance) بيخلي الموديل يركز على أقوى ميزة ظهرت ويخليه مايهتمش أوي بالمكان الدقيق للميزة دي

8. AlexNet: مثال عملي

- Fully و 3 طبقات Convolution ده الموديل اللي عمل ثورة سنة 2012. كان عبارة عن 5 طبقات Connected.
- أهم مميزاته:
 - ، وده خلى التدريب أسرع 6 مرات Tanh كدالة تنشيط بدل ReLU استخدم
 - (يمنع الموديل إنه يحفظ الصورة صم) Overfitting عشان يقلل الـ Dropout استخدم
 - (قص الصور وقلبها) عشان يزود الداتا Data Augmentation استخدم
 - . لأن حجمه كان كبير وقتها (GPUs) اتدرب على 2 كارت شاشة

9. Transfer Learning) نقل التعلم

- **!ماتبدأش تدريب من الصفر لو مش مضطر**: دي أهم نصيحة في المحاضرة
- يكون مدرب جاهز على ملايين الصور (ResNet أو AlexNet زي) لو معاك داتا قليلة، هات موديل كبير. الموديل ده "فاهم" يعني إيه حواف وأشكال (ImageNet).
- إزاي تعملها؟
 - ، وخط طبقة جديدة لداتا (Classifier) جمد الموديل كله وشيل بس آخر طبقة **Feature Extractor**: بتاعتك ودرّب الطبقة دي بس

- **Fine-tuning:** لو معاك داتا أكثر شوية، ممكن تفتح التدريب لأخر كام طبقة في الموديل عشان يظبط نفسه على صورك إنت.

، وفي Pooling بتشوف الصور عن طريق فلاتر بتدور على ميزات محددة، وبنصغر الصورة بالـ CNN الـ باختصار من موديل جاهز Transfer Learning الآخر بنوصل لقرار. ولو معندكش داتا كتير، استخدم

أسألة:

باللغة الإنجليزية بتغطي كل تفاصيل المحاضرة MCQ دي قائمة بـ 50 سؤال بناءً على الملفات، مع الإجابة والشرح المبسط بالمصري (Learning).

Section 1: CNN Fundamentals & Operations

1. What is the main disadvantage of using a fully connected MLP for high-resolution images?

- A. It cannot model non-linear functions.
- B. It requires a massive number of parameters, leading to overfitting and high memory usage.
- C. It is translation invariant by default.
- D. It only works with grayscale images.

- **Correct Answer: B**

- بيبقى (Parameters) بتوصل كل بيكسل بكل نيورون، فلو الصورة كبيرة عدد الأوزان MLPs الـ:التفسير (Overfit) ملايين، وده بيتقل الجهاز وبيخلي الموديل يحفظ

2. In a Convolutional Neural Network, what is "Sparse Interaction"?

- A. Every output unit interacts with every input unit.
- B. The kernel size is larger than the input size.
- C. Each output unit is connected only to a small local region of the input (receptive field).
- D. Most weights in the network are set to zero.

- **Correct Answer: C**

- على قد حجم (Local region) النيورون مش بيبص على الصورة كلها، بيبص بس على حطة صغيرة :التفسير الفلتر.

3. What does "Parameter Sharing" mean in the context of CNNs?

- A. Different filters are used for different parts of the image.
- B. The same kernel (weights) is slid across the entire input image.
- C. Weights are shared between the generator and discriminator.
- D. Parameters are shared between the training and test sets.

- **Correct Answer: B**

- الفلتر (زي كاشف الحواف) اللي بيشتغل في يمين الصورة هو نفس الفلتر (نفس الأرقام) اللي بيشتغل :التفسير في شمالها، وده بيوفر ميموري جداً.

4. What property does parameter sharing confer to the convolutional layer?

- A. Rotation invariance.
- B. Scale invariance.
- C. Equivariance to translation.
- D. Invariance to lighting changes.

- **Correct Answer: C**

- معناه لو المدخل اتحرك (انزاح)، المخرج كمان هيتحرك بنفس الطريقة (Equivariance) التكافؤ :التفسير.

5. Which mathematical operation is typically implemented in deep learning libraries for convolution?

- A. True Convolution (with kernel flipping).
- B. Cross-correlation (without kernel flipping).
- C. Fourier Transform.
- D. Matrix Inversion.

- **Correct Answer: B**

- Convolution (مبتقلبش الفلتر) وبنسميها مجازاً Cross-correlation بتنفيذ PyTorch المكتبات زي :التفسير للسهولة.

6. If you have an input of size W_{in} , kernel size k , stride s , and padding p , what is the output width formula?

- A. $(W_{in} - k + 2p) / s + 1$
- B. $(W_{in} + k - 2p) * s$
- C. $W_{in} * k / s$
- D. $W_{in} - k + 1$

- **Correct Answer: A**

- دي المعادلة الأساسية لحساب حجم الصورة اللي خارجة من الفلتر: **التفسير**

7. What is the primary purpose of "Zero Padding"?

- A. To increase the number of channels.
- B. To preserve the spatial dimensions (width and height) of the input after convolution.
- C. To remove edges from the image.
- D. To increase the stride.

- **Correct Answer: B**

- بيزود أصفار حوالين الصورة عشان حجمها ميصغرش لما نمشي عليها الفلتر (Padding) الحشو: **التفسير**

8. What does a "Stride" of 2 do to the spatial dimensions of the output?

- A. It doubles the dimensions.
- B. It keeps the dimensions the same.
- C. It roughly halves the dimensions (downsampling).
- D. It squares the dimensions.

- **Correct Answer: C**

- يعني الخطوة. لو بننط خطوتين بدل واحدة، بنفوت بيكسلات، فالصورة الناتجة بتصغر للنص Stride الـ: **التفسير** تقريباً.

9. Why are 1x1 convolutions useful in CNN architectures?

- A. They effectively capture spatial patterns like edges.
- B. They are used to increase the image resolution.
- C. They perform dimensionality reduction (reducing the number of depth channels) efficiently.
- D. They replace the pooling layers.

- **Correct Answer: C**

- ، فينستخدمه عشان نضغط عدد القنوات (مثلاً من 192 لـ 32) Depth بيشغل على الـ 1x1 conv الـ: **التفسير** ونوفر حسابات.

10. In a convolutional layer, the filter depth (number of channels in the kernel) must always match:

- A. The width of the input.
- B. The height of the input.
- C. The depth of the input volume.
- D. The number of filters in the next layer.

- **Correct Answer: C**

- (3 قنوات)، الفلتر لازم يكون RGB الفلتر لازم يكون نفس "عمق" الصورة اللي داخله. لو الصورة: **التفسير** عمقه 3.
-

Section 2: Pooling & Receptive Fields

11. What is the main function of a Pooling layer?

- A. To introduce non-linearity.
- B. To reduce the spatial size (downsampling) and computation while retaining important features.
- C. To increase the number of parameters.
- D. To zero out negative values.

- **Correct Answer: B**

- ببصغر الصورة (زي التلخيص) عشان يقلل الحسابات ويركز على الميزات المهمة Pooling الـ: **التفسير**

12. Max Pooling introduces a degree of invariance to:

- A. Rotation.
- B. Small translations (shifts).
- C. Color changes.
- D. 3D perspective changes.

- **Correct Answer: B**

- لأنه بياخد أكبر قيمة في المربع، فلو الميزة اتحركت حته صغيرة جوه نفس المربع، النتيجة مش هتتغير: **التفسير**

13. What is the standard backpropagation rule for Max Pooling?

- A. The gradient is split equally among all inputs.
- B. The gradient is passed only to the input unit that had the maximum value (argmax).
- C. The gradient is multiplied by zero.
- D. The gradient is passed to all units.

- **Correct Answer: B**

- بس للمكان اللي كان فيه الرقم الكبير (الماكس) اللي اخترناه، Gradient ، بنرجع الـ Backprop في الـ: **التفسير** وباقي الأماكن بتاخذ صفر.

14. What happens to the "Receptive Field" as we go deeper into the network?

- A. It stays the same size.
- B. It becomes smaller.
- C. It becomes larger, covering more of the original input image.
- D. It becomes 1x1.

- **Correct Answer: C**

- كل ما تدخل أعماق، النيورون يشوف منطقة أوسع من الصورة الأصلية لأنه يجمع معلومات من طبقات: **التفسير** قبله.

15. What is a "Dilated Convolution"?

- A. A convolution that shrinks the image.
- B. A convolution where the filter weights are expanded with spaces (zeros) to increase the receptive field without adding parameters.
- C. A fully connected layer.
- D. A 1x1 convolution.

- **Correct Answer: B**

- بيوسع الفلتر (بيخرمه) عشان يشوف مساحة أكبر من غير ما نزود عدد الـ Dilated conv الـ: **التفسير** parameters.

16. Why might one prefer to get rid of pooling layers in modern architectures (like VAEs or GANs)?

- A. Because pooling is too slow.
- B. To preserve spatial information and allow the network to learn its own downsampling (via strided conv).
- C. Because pooling increases overfitting.
- D. Because pooling requires too much memory

- **Correct Answer: B**

- بـ Convolution ، بنفضل نستخدم (Generative خاصة اللي بتولد صور) في الموديلات الحديثة: **التفسير** Stride عشان نحافظ على التفاصيل المكانية Pooling عالي بدل الـ.

17. How many learnable parameters does a standard Max Pooling layer have?

- A. It depends on the filter size.
- B. It depends on the input depth.
- C. Zero parameters.
- D. One parameter (bias).

- **Correct Answer: C**

- دي عملية حسابية ثابتة (هات الماكس)، مفيهاش أي أوزان بتتعلم Pooling الـ: **التفسير**

18. What is "Overlapping Pooling" as used in AlexNet?

- A. When stride is larger than the kernel size.

B. When stride is smaller than the kernel size ($s < z$).

C. When stride equals the kernel size.

D. When padding is used with pooling.

- **Correct Answer: B**

- AlexNet يعني الشبكات التي بناه من الماكس بيتداخل مع الشبكات التي بعده، وده قلل نسبة الخطأ في التفسير شوية.

19. Which filter is typically used for edge detection?

A. A filter with all ones.

B. A Gaussian blur filter.

C. A Sobel filter (e.g., $[-1, 0, 1]$).

D. A 1×1 filter.

- **Correct Answer: C**

- بتقدر تطلع الحواف عن طريق حساب الفرق بين البيكسلات المتجاورة Sobel فلاتر زي التفسير.

20. If an input volume is $32 \times 32 \times 3$ and we apply 10 filters of size $5 \times 5 \times 3$ with stride 1 and pad 0, the output volume depth will be:

A. 3

B. 5

C. 10

D. 32

- **Correct Answer: C**

- عمق الخرج بيساوي عدد الفلاتر التي استخدمناها. استخدمنا 10 فلاتر يبقى العمق 10: التفسير.

Section 3: Architectures (LeNet & AlexNet)

21. LeNet-5 was originally designed for which task?

A. ImageNet classification.

B. Handwritten digit recognition (MNIST).

C. Face detection.

D. Object detection in video.

- **Correct Answer: B**

- صممت عشان تتعرف على الأرقام المكتوبة بخط اليد في الشبكات والجوابات LeNet-5 شبكة: التفسير.

22. Which activation function did AlexNet use to speed up training compared to traditional Tanh?

A. Sigmoid.

B. Softmax.

C. ReLU (Rectified Linear Unit).

D. Leaky ReLU.

- **Correct Answer: C**

- ، فخلت (Non-saturating) كانت طفرة لأنها سريعة جداً في الحساب ومبتعملش تشبع ReLU الـ :التفسير
التدريب أسرع 6 مرات

23. What technique did AlexNet use to reduce overfitting? A. Batch Normalization. B. Dropout and Data Augmentation. C. Layer Normalization. D. Removing all fully connected layers.

- **Correct Answer: B**
- (بيطفي نيورونز عشوائي) و Dropout استخدموا :التفسير
Overfitting والقلب) عشان يقللوا الـ

24. How did AlexNet handle the limitation of GPU memory at the time (2012)? A. It used a smaller model. B. It trained on CPUs only. C. It split the model across two GPUs (Grouped Convolution). D. It used grayscale images only.

- **Correct Answer: C**
- ، وكانوا بيتواصلوا مع بعض في (GTX 580) قسموا الموديل نصين، كل نص شغال على كارت شاشة :التفسير
طبقات معينة بس

25. What is the role of Local Response Normalization (LRN) in AlexNet? A. To zero out gradients. B. To aid generalization by creating competition between neuronal outputs (lateral inhibition). C. To replace ReLU. D. To reduce the image size.

- **Correct Answer: B**
- كانت بتعمل نوع من "المنافسة" بين النيورونز النشطة، وده ساعد في تحسين التعميم LRN الـ :التفسير
(Generalization) وقتها

26. In the visualization of AlexNet's first layer filters, what do they typically resemble? A. Faces and objects. B. Random noise. C. Gabor-like filters (edges, bars) and color blobs. D. Text characters.

- **Correct Answer: C**
- المعروفة Gabor والألوان، ويتشبه فلاتر الـ (Edges) أول طبقة دايماً بتتعلم حاجات بسيطة زي الحواف :التفسير

27. What happened when layer 7 (a fully connected layer) was removed from AlexNet? A. The performance dropped significantly (e.g., ~1%). B. The performance increased. C. The model stopped working completely. D. The number of parameters increased.

- **Correct Answer: A**
- قلل الدقة بس بنسبة بسيطة (1.1%)، وده يوضح إن الطبقات دي فيها تكرار FC حذف طبقة :التفسير
(Redundancy).

28. What happened when convolutional layers (3, 4, 6, 7) were removed from AlexNet?

A. Little change in performance. B. Massive drop in performance (e.g., ~33%). C. Training became faster with better accuracy. D. Nothing.

- **Correct Answer: B**

- مهم جداً (Depth) "مع بعض، الأداء انهار. ده يثبت إن "العمق FC والـ Conv لما شالوا طبقات الـ:التفسير للموديل.

29. Why are fully connected layers usually placed at the end of a CNN? A. To extract spatial features. B. To combine the high-level features and perform the final classification. C. To reduce the parameter count. D. To act as a pooling layer.

- **Correct Answer: B**

- طلعتها عشان تاخذ القرار النهائي (ده كلب ولا قطة) Convolution بتلم كل الميزات اللي الـ FC الـ:التفسير.

30. How many parameters (approx.) did AlexNet have? A. 1 Million. B. 60 Million. C. 1000. D. 1 Billion.

- **Correct Answer: B**

- Fully Connected. أليكس نت كان فيها حوالي 60 مليون باراميتير، أغلبهم في طبقات الـ:التفسير.

Section 4: Transfer Learning

31. What is the core idea of Transfer Learning? A. Training two models simultaneously. B. Using weights from a pre-trained model (on a large dataset) to solve a task on a different (often smaller) dataset. C. Transferring data from CPU to GPU. D. Converting images to text.

- **Correct Answer: B**

- على داتا كبيرة، وننقله يحل مشكلة عندنا داتا قليلة فيها (Pre-trained) بناخد موديل اتعلم خلاص:التفسير.

32. When is Transfer Learning most beneficial? A. When the target dataset is huge. B. When the target dataset is small and scarce. C. When we have unlimited computational resources. D. When the source and target domains are completely unrelated (e.g., audio to images).

- **Correct Answer: B**

- أهم فائدة ليه لما تكون الداتا اللي معاك قليلة ومش كفاية تدرب موديل من الصفر:التفسير.

33. In the "Feature Extractor" approach of Transfer Learning, what do we do? A. Train the entire network from scratch. B. Freeze the convolutional base and only train the new classifier (top layers). C. Randomize all weights. D. Use unsupervised learning.

• **Correct Answer: B**

- بنجمد الموديل الأصلي (نستخدمه كأنه بيطلع ميزات بس) وندرب بس آخر طبقة عشان توفر وقت وتمنع **:التفسير** الـ Overfitting.

34. What is "Fine-tuning" in Transfer Learning? A. Adjusting the hyperparameters only. B. Unfreezing some of the top layers of the pre-trained base and retraining them along with the classifier. C. Training for only 1 epoch. D. Increasing the image resolution.

• **Correct Answer: B**

- يعني بنفتح التدريب لآخر كام طبقة في الموديل الأصلي عشان يظبط نفسه بدقة أكثر Fine-tuning الـ **:التفسير** . على الداتا الجديدة.

35. If your target dataset is small and very similar to the source dataset (e.g., ImageNet), you should: A. Fine-tune the whole network. B. Use the model as a Feature Extractor (train linear classifier on top). C. Train from scratch. D. Use a larger model.

• **Correct Answer: B**

- عشان (Fine-tuning) طالما الداتا متشابهة وقليلة، الموديل الجاهز فاهمها كويس، فمش محتاج تعديل **:التفسير** Classifier. كفاية تدرب الـ (Overfit) مبيصممش.

36. If your target dataset is large and different from the source dataset, you should: A. Fine-tune the whole network (or a large part of it). B. Use fixed feature extraction. C. Avoid transfer learning completely. D. Use only the first layer.

• **Correct Answer: A**

- عشان يتعلم الفروقات الجديدة (Fine-tune all) بما إن معاك داتا كتير، تقدر تفتح التدريب للموديل كله **:التفسير** Overfitting. من غير خوف من الـ

37. Which layers contain more "generic" features (like edges and colors)? A. The top fully connected layers. B. The middle convolutional layers. C. The first few convolutional layers (lower layers). D. The output layer.

• **Correct Answer: C**

- "الطبقات الأولى بتتعلم أساسيات (حواف وألوان) ودي موجودة في كل الصور، عشان كدة هي "عامة **:التفسير** (Generic).

38. Which layers contain more "specific" or semantic features (like object parts)? A.

The first layer. B. The deeper (upper) convolutional layers. C. The input layer. D. The pooling layers.

- **Correct Answer: B**

- الطبقات العميقة بتفهم أشكال معقدة (وشوش، عجل عربيات) ودي ممكن تختلف من داتا للتانية :التفسير

39. When fine-tuning, what kind of learning rate should be used for the pre-trained weights? A. A very large learning rate. B. A smaller (mild) learning rate (e.g., 0.1x of original).

C. The same learning rate as scratch training. D. Zero learning rate.

- **Correct Answer: B**

- عشان منبوظش الأوزان اللي الموديل اتعلمها قبل كده، إحنا بس (Small LR) بنستخدم رقم صغير :التفسير "عايزين" تطبيق بسيط

40. What must always be replaced when transferring a model to a new task? A. The first convolutional layer. B. The max pooling layers. C. The final classification layer (to match the number of classes). D. The activation functions.

- **Correct Answer: C**

- في داتا بتاعتنا (مثلاً 2) غير الداتا الأصلية (مثلاً 1000) Classes لازم نغير آخر طبقة لأن عدد الـ :التفسير

Section 5: Miscellaneous & Advanced

41. How does the number of operations for a 1x1 convolution compare to a larger filter (e.g., 5x5)? A. It is much higher. B. It is significantly lower (computationally cheap). C. It is exactly the same. D. It depends on the padding.

- **Correct Answer: B**

- عملية رخيصة جداً مقارنة بالفلاتر الكبيرة، عشان كدة بنستخدمها لتقليل الأبعاد 1x1 الـ :التفسير

42. Which of the following is NOT a benefit of CNNs over MLPs? A. Parameter sharing. B. Sparsity of connections. C. Equivariance to translation. D. Requiring manual feature extraction (e.g., SIFT/HOG).

- **Correct Answer: D**

- ML لوحدها، مش محتاجة استخراج يدوي زي الـ (Learned features) بتتعلم الميزات CNN الـ :التفسير القديم

43. What is the typical shape of a 3D input volume to a CNN? A. (Height, Width). B. (Height, Width, Channels). C. (Batch, Channels). D. (Vector).

- **Correct Answer: B**

- (RGB) الصور بتدخل كحجم ثلاثي الأبعاد: الطول، العرض، وعدد قنوات الألوان: **التفسير**.

44. According to Hubel and Wiesel's research (inspired CNNs), specialized cells in the brain detect: A. Complete objects instantly. B. Simple patterns like oriented edges and bars. C. Text only. D. 3D motion.

- **Correct Answer: B**

- اكتشفوا إن قشرة المخ البصرية فيها خلايا متخصصة لكشف الحواف والخطوط المائلة، وده ألهم فكرة **التفسير** CNN الفلاتر في الـ.

45. What implies that deep layers in a CNN can be indirectly connected to the entire input image? A. Because they are fully connected. B. Because of the growing effective receptive field. C. Because of the bias term. D. Because of 1x1 convolutions.

- **Correct Answer: B**

- ، النيورون بيشوف منطقة أكبر، لحد ما في الآخر ممكن النيورون Pooling و Conv كل ما بنعمل **التفسير** الواحد يكون شايف الصورة كلها تقريباً.

46. Which technique is used to synchronize gradients across multiple GPUs in Distributed Data Parallel training? A. All-reduce. B. Parameter Server. C. Random sampling. D. Dropout.

- **Correct Answer: A**

- من كل الكروت وتوزع المتوسط بتاعهم عليهم Gradients بتستخدم عشان تجمع الـ All-reduce تقنية **التفسير** كلهم.

47. "Features learned in early layers are generic, while those in later layers are specific." This statement supports: A. Random initialization. B. Transfer Learning. C. Dropout. D. Data Augmentation.

- **Correct Answer: B**

- Transfer Learning بما إن الأولانيين "عامين"، نقدر ننقلهم لأي موديل ثاني، وده أساس فكرة الـ **التفسير**.

48. Why is "Symmetry" a problem if we initialize all weights to zero? A. It causes exploding gradients. B. All neurons in a layer will learn the same features (no diversity). C. It causes vanishing gradients. D. It makes the model too slow.

- **Correct Answer: B**

- لو بدأنا بصفر، كل النيورونز هتتحرك زي بعض بالطبط، فلأزم نكسر التماثل ده بأرقام عشوائية: **التفسير** (Recap concept).

49. What is a "bottleneck" layer in CNNs (often used in Inception/ResNet)? A. A layer with very large filters. B. A 1x1 convolution used to reduce dimension before a computationally expensive operation. C. The output layer. D. The input layer.

- **Correct Answer: B**

- عشان تقلل الداتا وتخلي الحسابات أخف وأسرع 1x1 طبقة "عنق الزجاجة" بتستخدم 1: **التفسير**.

50. What visual pattern does a "Checkerboard artifact" usually indicate in CNN images? A. Perfect training. B. Issues with deconvolution (transposed convolution) overlaps. C. Use of ReLU. D. Excessive dropout.

- **Correct Answer: B**

- Deconvolution (معلومة) دي مشكلة بتحصل في توليد الصور لما يكون في تداخل مش متساوي في الـ: **التفسير** (إضافية ذات صلة بالمحاضرات المتقدمة).

شرح مفصل:

بالفصيل الممل، خطوة خطوة، وباللهجة المصرية البسيطة، (Lecture 5 - CNN) أهلاً بيك. هشرحلك المحاضرة الخامسة **(Convolutional Neural Networks)** عشان نفهم كل "فسفوسة" في الملفات اللي بعتها. المحاضرة دي بتتكلم عن الشبكات العصبية الالتفافية **CNN** واختصارها.

:خلينا نقسم الشرح لنقط رئيسية

1. (MLP) إيه المشكلة في الشبكات القديمة؟

(الشبكات العصبية العادية اللي كل حاجة فيها متوصلة بكل حاجة) مش بتنفع مع MLP في الأول، الملف بيعرض ليه الـ الصور:

- لو فردت (RGB يعني 3 قنوات ألوان) تخيل عندك صورة صغيرة حجمها 400×400 بيكسل وملونة: **المشكلة** هتبقى عبارة عن 480,000 رقم (Vector) الصورة دي في صف واحد.
- واحدة فيها 500 نيورون بس، ووصلنا كل نيورون بكل بيكسل، هحتاج (Hidden Layer) لو عملنا طبقة مخفية للطبقة دي بس (Parameter) مليون وزن 240
- (Overfitting) والشبكة هت حفظ الصورة صم (Memory issues) ده رقم خرافي، هخلي الجهاز يهنج: **النتيجة** ومش هتتعلم بجد.

2. الـ Convolution (الالتفاف) الحل: الـ

على القطط). اكتشفوا إن خلايا المخ المسؤولة عن النظر مش Hubel & Wiesel الفكرة جت من دراسة المخ (تجربة أو خطوط (Edges) "بتبص على الصورة كلها مرة واحدة، دي بتبص على حثت صغيرة وتدور على "حواف

Convolution؟ يعني إيه

- صغير (مثلاً مربع 3×3 أو 5×5) "Kernel" أو (Filter) "بدل ما نوصل النيورون بالصورة كلها، بنعمل "فلتر
- الفلتر ده بيمشي (يزحف) على الصورة حته حته. بيبضرب الأرقام اللي جواه في أرقام الصورة ويجمعهم ويطلع رقم واحد.
- بس إحنا مجازاً بنقول عليها Cross-correlation في الرياضيات بيسموها **Convolution** العملية دي اسمها Convolution.

مميزات الطريقة دي (ليه هي عبقرية؟)

1. **Sparse Interaction (توصيل محلي)**: الـ نيورون مش بيبص على الصورة كلها، بيبص بس على المربع (توصيل محلي) **Sparse Interaction**. الصغير اللي تحته. ده بيقلل عدد التوصيلات جداً.
2. **Parameter Sharing (مشاركة الأوزان)**: دي أهم نقطة. الفلتر اللي اتعلم يكتشف "خط بالطول" في أول (مشاركة الأوزان) **Parameter Sharing** الصورة، هو هو نفس الفلتر (بنفس الأرقام) اللي هنمشيه على باقي الصورة عشان يكتشف نفس الخط في أي مكان. يعني مش محتاجين نعمل فلتر جديد لكل حته في الصورة. ده بيوفر ملايين الباراميترز.
3. **Equivariance (التكافؤ)**: لو الجسم اللي في الصورة اتحرك يمين، النتيجة اللي طالعة من الفلتر (التكافؤ) **Equivariance** (Activation map) هتتحرك يمين هي كمان.

3. الـ Stride & Padding (تفاصيل "المشي" على الصورة)

عشان الفلتر يشتغل صح، لازم نحدد بيمشي إزاي

- **Stride** (الخطوة) $(Stride = 1)$ الفلتر يمشي مربع مربع (الخطوة) $(Stride = 1)$ ولا بينط؟
 - حجمها يصغر (Output) ، الفلتر هينط خطوتين، وده بيخلي الصورة الناتجة $Stride = 2$ لو عملنا للنص تقريباً.
 - **Padding** (الحشو): عشان نحافظ على حجم الصورة زي ما هو، بنزود بـ 1 من الأضلاع حولين الصورة الأصلية.
- (حجم الصورة - حجم الفلتر + $2 \times$ الحشو) / الخطوة + 1 : حجم الصورة اللي خارجة بيتحسب إزاي؟ المعادلة

4. التعامل مع الألوان (3D Volumes)

(قنوات 3 RGB اللي هو ألوان الـ Depth) "الصورة مش ورقة مسطحة، دي ليها "عمق

- عشان كده، الفلتر بتاعنا لازم يكون "مكعب" مش مربع. لو الصورة عمقها 3، الفلتر لازم يكون عمقه 3 (مثلاً $3 \times 3 \times 3$).
- وعشان نطلع ميزات كتير، بنستخدم كذا فلتر (مثلاً 64 فلتر)، (2D) الناتج من الفلتر الواحد بيكون شريحة واحدة فالخرج النهائي بيبقى "مكعب" عمقه 64.

1x1 Convolution:

- ممكن تستغرب، إيه فائدة فلتر حجمه 1×1 ؟ ده بيبص على بيكسل واحد بس
- كله (كل القنوات). بنستخدمه عشان نغير عدد القنوات Depth الفلتر ده بيبص على البيكسل بس عبر الـ **لازمته** أو عنق الزجاجة "Bottleneck" (مثلاً نقلل العمق من 192 لـ 32) بطريقة حسابية رخيصة وسريعة. بيسموها لتقليل الحسابات

5. التلخيص (Pooling Layer)

، الصورة بتبقى لسه كبيرة وتقلية. بنحتاج نصغرها ونركز على المهم Convolution بعد ما بنطلع الميزات بالـ

- **Max Pooling**: دي أشهر طريقة. بنقسم الصورة مربعات (مثلاً 2×2)، ومن كل مربع بنأخذ أكبر رقم بس ونرمي الباقي.
- **ليه بنعمل كده؟**
 1. (Downsampling) عشان نقلل حجم البيانات والحسابات.
 2. (مش فارق معاه) للتغيرات البسيطة في المكان. يعني لو ودين القطة **Invariant** عشان نخلي الموديل هيلقطها برضه لأنها لسه جوه المربع Max Pooling اتحركت ملي يمين، الـ

6. (موديل غير التاريخ) AlexNet: قصة نجاح

Deep Learning بفرق رهيب عن المنافسين، وده كان بداية عصر الـ ImageNet سنة 2012، الموديل ده كسب مسابقة:
اللي اتشرفت AlexNet أهم مميزات الحقيقي:

1. **ReLU Activation:** ReLU بدل Tanh أو Sigmoid. الـ ReLU خلّت التدريب أسرع 6 مرات (Saturation) "لأنها بسيطة ومفيهاش مشكلة" تلاشي التدرج.
2. **Dropout:** كانوا بيطفوا 50% من النيورونز عشوائياً في كل (Overfitting) عشان يمنعوا الشبكة إنها تحفظ، مرة تدريب. ده بيحبر الشبكة تتعلم ميزات قوية ومش معتمدة على نيورون بعينه.
3. **Data Augmentation:** (Mirror) الداتا كانت قليلة، فعملوا حيل ذكية: بقوا يقصوا الصور، يقلبوها، إضاءة الألوان، عشان يزودوا عدد الصور والشبكة تتعود على أشكال مختلفة.
4. **Training on GPUs:** وكانوا بيتواصلوا (GTX 580) عشان الشبكة كانت ضخمة، قسموها على كارتين شاشة مع بعض في طبقات معينة بس.

7. (Transfer Learning) نقل التعلم

دي أهم "هدية" في المحاضرة. السؤال هو: هل لازم كل مرة أدرب الموديل من الصفر؟

- اتعلمت بالفعل يعني إيه "خواف"، "ألوان"، (ImageNet زي اللي اتدربت على) لأ! الشبكات الكبيرة: الإجابة "أشكال". دي معلومات عامة ومفيدة لأي مشكلة تانية.
- إزاي نستفيد منها؟

1. Feature Extractor (استخراج الميزات):

- هات الشبكة الجاهزة، جمدها (ماتخليهاش تتعلم جديد)، وشيل آخر طبقة بس (المسؤولة عن القرار).
- حط طبقة جديدة خاصة ببيك ودرب الطبقة دي بس. دي طريقة ممتازة لو الداتا بتاعتك قليلة.

2. Fine-tuning (الضبط الدقيق):

- لو معاك داتا أكثر شوية، ممكن تفتح التعليم لآخر كام طبقة في الشبكة الأصلية.
- صغير جداً (عشان متبوظش المعلومات القديمة اللي الشبكة Learning Rate بتستخدم عارفاه)، وتخليها تظبط نفسها على الداتا بتاعتك.

8. ملخص سريع لنصائح عملية:

- الطبقات الأولى في الشبكة بتتعلم حاجات عامة (خطوط وألوان)، الطبقات الأخيرة بتتعلم حاجات خاصة بالداتا. بنحب نحتفظ بالأول ونغير الأخير Transfer Learning (وشوش، عريبات). عشان كده في الـ

- لوحدها، لازم تعلمها بصور مقلوبة (Rotation) "قوية جداً لكن مش بتفهم" الدوران CNN الـ (Augmentation).
- (مجال الرؤية للنيورون) بيكبر، وبيقدر يشوف Receptive Field ، كل ما الـ (Deep) كل ما الشبكة تكون أعمق .الصورة كاملة في الآخر

!دي كانت كل تفصيلة في المحاضرة مشروحة ببساطة. لو في جزء معين عايزني أركز عليه أكثر أو أديك مثال عليه، قولي