

LEC. 5

ملخص:

1. Deep Embeddings يعني إيه؟

- تخيل الصورة دي عبارة عن "دوشة" أرقام كتيرة جداً (مثلاً 150 ألف رقم). الشبكة العصبية بتعمل عملية: **الفكرة** "عصر" للصورة دي عشان تحولها لعدد قليل من الأرقام (مثلاً 2048 رقم بس).
- دي بتمثل "الزتونة" أو المعنى الحقيقي **Latent Space** أو **Embeddings** الأرقام القليلة دي بنسميها: **الفائدة** للصورة (زي إن فيها قطعة أو كلب) من غير تفاصيل مالهاش لازمة زي لون الخلفية بالظبط.

2. (الأعمق أحسن) شبكة VGGNet

- كل ما نكثر الطبقات، الشبكة تفهم أحسن. "وقالت: "يا جماعة السر في العمق AlexNet دي جت بعد
- بس في كل حبة $3 \times 3 \times 3$ استخدموا فلاتر صغيرة جداً بحجم: **السر بتاعها**
- $3 \times 3 \times 3$ ؟
 - فوق بعض، هيدوك نفس نتيجة فلتر واحد كبير $5 \times 5 \times 3$ اكتشفوا إن لو حطيت طبقتين $3 \times 3 \times 3$ ، بس بعدد باراميترز (أوزان) أقل، وحسابات أسرع، وكمان بيدينا فرصة نحط دالة تنشيط $5 \times 5 \times 3$ أكثر، فالموديل يبقى أذكى (Non-linearity).

3. (العريضة والذكية) شبكة GoogleNet

- أنا هشغلهم كلهم مع $5 \times 5 \times 3$ ولا $5 \times 5 \times 3$ الموديل ده حب يفتكس وقال: "ليه أختار أختار فلتر 3×3 ؟! بعض
- **Inception Module**: دي "وحدة" جوه الشبكة بتشغل فلاتر بمقاسات مختلفة $1 \times 1 \times 3$, $3 \times 3 \times 3$, $5 \times 5 \times 3$ بالتوازي، وتجمع النتائج في الآخر $5 \times 5 \times 3$.
- كأنه "بوابة" تقلل **$1 \times 1 \times 3$ Convolution** الكلام ده كان ثقيل جداً عالحواسبات، فاستخدموا: **مشكلة وحل** قبل ما تدخل عالفلتر الكبيرة، عشان الشبكة متهنّجش (Dimension reduction) حجم البيانات
- **Auxiliary Classifiers** (Vanishing Gradient) عشان الشبكة كانت عميقة، الإشارة كانت بتضيع وهي راجعة Error ، فعملوا "مخارج فرعية" في نص الشبكة تحسب الـ

4. (Skip Connections ثورة الـ) شبكة ResNet

- دي أهم شبكة فيهم، قدرت توصل لـ 152 طبقة وأكثر (قبلها كان آخره 20-30 طبقة)
- (Optimization) لقوا إن لما بيزودوا الطبقات أوي، دقة الشبكة بتقل مش بتزيد، لأنها مش عارفة تتعلم: **المشكلة** (issue).

- يعدي البيانات من فوق الطبقة (Skip Connection) "عملوا" كوبري: **(Residual Block)** الحل العبقري
ويجمعها على الخرج.
 - المعادلة بقت: $y = F(x) + x$.
 - ، ولو الطبقة مالهاش لازمة، الشبكة بتخليها صفر وتعدي (Residual) ده خلى الشبكة تتعلم "الفرق" بس
، فبقى سهل جداً ندرّب شبكات عميقة جداً (\$Identity Mapping\$) البيانات زي ما هي.

5. شبكات ثانية مهمة

- **DenseNet**: هنا كل طبقة بنتوصل بكل الطبقات اللي وراها. كل واحد بيدي اللي قبله للي بعده، عشان نضمن
إن مفيش معلومة تضيع.
- **MobileNet**: عشان **Depthwise Separable Convolution** معموله للموبايلات. بتستخدم حيلة اسمها
تقلل الحسابات جداً وتخلي الموديل خفيف وسريع.
- **BagNet**: بتاع حنت (Texture) "دي أثبتت إن الشبكات ساعات بتغش و"بتبصم". بتعرف الصورة من "الملمس"
صغيرة مش من الشكل الكامل للجسم.

6. تطور اكتشاف الأجسام (Object Detection)

؟(Bounding Box) إزاي نطلع مربع حوالين الجسم

- **R-CNN (الجد البطيء)**:
 - تقترح عليه Selective Search بياخد الصورة، ويستخدم خوارزمية (مش ذكاء اصطناعي) اسمها
2000 مربع ممكن يكون فيهم حاجة.
 - تخيل 2000 مرة للصورة الواحدة! بطيئة جداً. CNN ياخذ كل مربع لوحده يدخله على
- **Fast R-CNN (الأسرع شوية)**:
 - (Features) ، وبعدين ناخذ الميزات CNN قالك وليه التعب؟ ندخل الصورة كلها مرة واحدة على الـ
بقت أسرع بكثير. (RoI Pooling) ونقص منها الحنت اللي عايزينها
- **Faster R-CNN (السرّيع والذكي)**:
 - **Region Proposal Network (RPN)** اسمها CNN خالص، وعمل شبكة صغيرة جوه الـ Selective Search لغى الـ
وبقت سريعة جداً (End-to-End) هي اللي تقترح الأماكن المهمة. كله بقى بيتعلم (Real-time).

7. التجزئة (Segmentation)

- **Mask R-CNN**:

- لون على قد (Mask) بدل ما يطلع مربع بس، بيطلع كمان Faster R-CNN دي التطور الطبيعي للـ (الجسم بالظبط).
- عشان يظبطوا الأبعاد بالمللي وميضيعوش تفاصيل البيكسلات RoIAlign استخدموا تقنية اسمها

(VGG, ResNet) ، وبعدين شفنا إزاي الشبكات كبرت وعمقت (Embeddings) المحاضرة بدأت بإننا بنضغط الصور: **الخلاصة** ، وفي الآخر اتعلمنا إزاي نحدد أماكن الأجسام بدقة (Skip Connections) ، وإزاي حلينا مشاكل التدريب (R-CNN family) وسرعة.

أسألة:

Section 1: Deep Embeddings & General Concepts

1. What is the primary function of a "Deep Embedding" in a CNN?

- A. To increase the resolution of the image.
- B. To perform dimensionality reduction and extract high-level semantic features.
- C. To colorize black and white images.
- D. To increase the number of pixels.

- **Correct Answer: B**

- بيحول الصورة الكبيرة (اللي فيها تفاصيل كتير زي الخلفية) لعدد قليل من الأرقام Embedding الـ: **التفسير** بتاع الصورة (Semantics) "بيعبّر عن" المعنى.

2. As we go deeper into the network layers, what happens to the features?

- A. They become more specific to pixel colors.
- B. They represent simple edges only.
- C. They become more abstract and high-level (semantic information increases).
- D. They disappear completely.

- **Correct Answer: C**

- الطبقات الأولى بتشوف خطوط وألوان، لكن كل ما تغمق، الشبكة بتفهم أشكال معقدة ومفاهيم مجردة أكثر: **التفسير**.

3. What is the typical input dimension for a standard ImageNet model (e.g., ResNet/VGG)?

- A. 28×28 (784 dimensions) B. $3 \times 224 \times 224$ (~150K dimensions)
C. $1 \times 1 \times 1000$ D. 4096 dimensions

• **Correct Answer: B**

- الدخل المعتاد سيكون صورة ملونة (3 قنوات) وحجمها 224 في 224 بيكسل: التفسير

Section 2: VGGNet

4. What was the main design philosophy behind VGGNet?

- A. Using very large filters (11×11).
B. Using parallel paths (Inception).
C. Simplicity and Depth (using only small 3×3 filters).
D. Using skip connections.

• **Correct Answer: C**

- "وزود الطبقات (العمق) قد ما تقدر 3×3 كانت بسيطة: "صغر الفلتر لـ VGG 3 فكرة: التفسير

5. Why are two stacked 3×3 convolutional layers preferred over one 5×5 layer?

- A. They cover the same receptive field but with fewer parameters and more non-linearity.
B. They are faster to compute. C. They cover a smaller area.
D. They require no padding.

• **Correct Answer: A**

- الفلترين الصغيرين بيشوفوا نفس المساحة اللي بيشوفها الفلتر الكبير، بس عددهم أقل في الحسابات، :التفسير
وبينهم دالة تنشيط زيادة فيخلوا الموديل أذكى

6. What is the receptive field size of three stacked 3×3 convolutional layers?

- A. 3×3 B. 5×5 C. 7×7 D. 9×9

• **Correct Answer: C**

- هيدوك نفس رؤية فلتر (3×3 to 5×5 to 7×7) كل طبقة بتزود 2 في المجال، فلو حطيت ثلاثة فوق بعض :التفسير
 7×7 .

7. In VGGNet, what happens to the number of filters (channels) after each max-pooling layer?

- A. It stays the same.
- B. It doubles (e.g., 64 -> 128).
- C. It is halved.
- D. It becomes 1.

- **Correct Answer: B**

- الضعف عشان نحافظ على (Channels) ، بنزود العمق (Spatial reduction) لما الصورة بتصغر :التفسير المعلومات.

Section 3: GoogLeNet (Inception)

8. What is the core component of the GoogLeNet architecture?

- A. The Residual Block.
- B. The Inception Module.
- C. The Dense Block.
- D. The Region Proposal Network.

- **Correct Answer: B**

- اللي بتشغل كذا فلتر مع بعض في نفس الوقت Inception جوجل نت قائمة على وحدة الـ :التفسير

9. Why does the Inception module use 1×1 convolutions before larger filters like 3×3 and 5×5 ?

- A. To increase the dimensions.
- B. To perform dimensionality reduction (bottleneck) and reduce computational cost.
- C. To blur the image.
- D. To act as a pooling layer.

- **Correct Answer: B**

- فبيققل حجم البيانات قبل ما تدخل على الفلاتر (Channels) ببيضغط عدد القنوات 1×1 الـ :التفسير الثقيلة، وده بيسرع الشبكة جداً

10. What technique did GoogLeNet use to handle the "Vanishing Gradient" problem during training?

- A. Skip connections.
- B. Auxiliary Classifiers connected to intermediate layers.
- C. Removing all activation functions.
- D. Using only one layer.

- **Correct Answer: B**

- في النص تحسب الخطأ (Auxiliary Classifiers) "عشان الشبكة طويلة، عملوا "مخارج فرعية: التفسير للآول Gradient وتساعد في توصيل الـ

11. How does GoogLeNet generate the final classification vector instead of using heavy Fully Connected layers?

A. Global Average Pooling. B. Max Pooling. C. Flattening. D. Zero padding.

- **Correct Answer: A**

- ويطلعوا (Channel) ، بياخدوا متوسط كل صورة parameters بدل ما يفردوا الصورة وتعمل زحمة: التفسير رقم واحد، وده وفر ملايين الأوزان

Section 4: ResNet

12. What phenomenon was observed when training very deep "plain" networks (without skip connections)?

A. They overfitted immediately.
B. The training error increased as the network became deeper (degradation problem).
C. They trained faster. D. The test error was zero.

- **Correct Answer: B**

- Overfitting بيزيد، مش بسبب الـ Error لقوا إن لما يزودوا الطبقات، الشبكة مش بتعرف تتعلم والـ: التفسير Optimization لكن بسبب صعوبة الـ

13. What is the mathematical formulation of a Residual Block?

A. $y = F(x)$ B. $y = F(x) + x$ C. $y = F(x) * x$ D. $y = x$

- **Correct Answer: B**

- بس، وده أسهل (Residual) "، فده بيخلي الشبكة تتعلم "الفرق $F(x)$ على الخرج x بنضيف الدخل: التفسير بكتير

14. Why is learning the identity mapping ($F(x) = 0$) easier in ResNet?

A. Because all weights are set to 1.
B. Because of the skip connection, the network just needs to push weights to zero to pass input as is.
C. Because it uses sigmoid activation. D. It is not easier.

- **Correct Answer: B**

- ، لو الطبقة دي مالهش لازمة، الشبكة بتخلي أوزانها صفر، والبيانات بتعدي زي Shortcut بوجود الـ:التفسير ما هي من الكوبري.

15. If the dimensions of the input x and output $F(x)$ do not match in a ResNet block, what is used?

- A. Error message.
- B. 1×1 convolution (projection shortcut) or zero padding.
- C. Max pooling.
- D. Dropout.

- **Correct Answer: B**

- عشان يظبط عدد القنوات أو الأبعاد عشان 1×1 conv لو الأحجام مش زي بعض، بنستخدم 1×1 :التفسير نعرف نجمعهم.

16. How deep can ResNets typically go while still training effectively?

- A. 20 layers max.
- B. 50, 101, or even 152+ layers.
- C. Only 8 layers like AlexNet.
- D. Infinite layers.

- **Correct Answer: B**

- .فتحت الباب لشبكات عميقة جداً بتوصل لـ 152 طبقة وأكثر من غير ما الأداء يقع ResNet الـ:التفسير

Section 5: DenseNet, MobileNet & BagNet

17. What is the connectivity pattern in a DenseNet?

- A. Each layer is connected only to the next one.
- B. Each layer is connected to all subsequent layers (feature reuse).
- C. Layers are not connected.
- D. Circular connections.

- **Correct Answer: B**

- ، كل طبقة بتأخذ شغل كل الطبقات اللي قبلها وتديه للي بعدها، عشان نضمن إن مفيش DenseNet في:التفسير ميزة تضيع.

18. What is the main advantage of MobileNets?

- A. Highest accuracy on ImageNet.
- B. Using Depthwise Separable Convolutions to reduce parameters and computation for mobile devices.
- C. Using huge filters.
- D. Requiring GPUs.

- **Correct Answer: B**

- ييفصل القنوات عن Convolution معمولة للموبايلات، فبتستخدم نوع خفيف من الـ MobileNet الـ:التفسير
عشان يوفر بطارية وسرعة (Depthwise) بعض.

19. What did the BagNet paper reveal about how CNNs recognize images?

- A. They look at the global shape of the object.
- B. They are biased towards local textures rather than global shapes.
- C. They work exactly like human vision.
- D. They ignore color.

- **Correct Answer: B**

- حثت (Texture) "أثبت إن الشبكات ساعات "بتبصم" وبتعرف الصورة من "لمس BagNet بحث:التفسير
صغيرة فيها، مش من الشكل الكامل للجسم.

20. In Depthwise Separable Convolution, standard convolution is split into:

- A. A depthwise convolution followed by a pointwise (1×1) convolution.
- B. Two 3×3 convolutions.
- C. A pooling layer and a dense layer.
- D. A convolution and a residual block.

- **Correct Answer: A**

- ، (Pointwise) وواحدة تلمهم مع بعض (Depthwise) العملية بتتقسم لخطوتين: واحدة لكل قناة لوحدها:التفسير
وده أرخص بكتير حسابياً.

Section 6: Object Detection (R-CNN Family)

21. What is the goal of Object Detection?

- A. Classify the whole image.
- B. Classify objects and draw bounding boxes around them.
- C. Segment every pixel.
- D. Generate new images.

- **Correct Answer: B**

- "و" مكانه فين (Localization/Bounding Box) "و" مكانه فين (Classification) "تحديد الأجسام يعني نقول "إيه ده :التفسير (Box).

22. How did the original R-CNN generate region proposals?

- A. Using a deep neural network.
- B. Using a fixed grid.
- C. Using an external algorithm called "Selective Search".
- D. Random guessing.

- **Correct Answer: C**

- عشان تقترح أماكن Selective Search كانت بتستخدم خوارزمية قديمة وبطيئة اسمها R-CNN الـ :التفسير الأجسام.

23. Why was the original R-CNN slow?

- A. It used a small GPU.
- B. It ran the CNN forward pass ~2000 times (once for each region proposal).
- C. It didn't use convolution.
- D. The images were too large.

- **Correct Answer: B**

- العيب القاتل إنها كانت بتأخذ كل مربع تقترحه وتدخله على الشبكة من الأول، فتخيل 2000 مرة للصورة :التفسير !الواحدة.

24. What was the main innovation of Fast R-CNN over R-CNN?

- A. Removing the CNN.
- B. Processing the whole image once and extracting features for regions using RoI Pooling.
- C. Using more layers.
- D. Using Selective Search.

- **Correct Answer: B**

- من جوه (Features) بقت تدخل الصورة كلها مرة واحدة، وبعدين تقطع الميزات Fast R-CNN الـ :التفسير الشبكة، فبقت أسرع بكثير.

25. What does RoI Pooling do?

- A. Downsamples the whole image.
- B. Converts features from a valid region of any size into a small fixed-size feature map (e.g., 7×7).

C. Increases the resolution of the region.

D. Rotates the region.

- **Correct Answer: B**

- **التفسير:** وظيفتها إنها تأخذ المربع (مهما كان حجمه) وتحوله لمربع ثابت صغير عشان ينفع يدخل على باقي الشبكة.

26. Which bottleneck did Faster R-CNN remove?

A. The CNN processing time.

B. The slow external "Selective Search" algorithm.

C. The classification layer.

D. The input loading time.

- **Correct Answer: B**

- **التفسير:** (RPN) واستبدلته بشبكة جوه الموديل نفسه Selective Search لغت الـ Faster R-CNN الـ.

27. What is the Region Proposal Network (RPN) in Faster R-CNN?

A. A separate neural network for classification.

B. A fully convolutional network that predicts object bounds and scores at each position (using anchors).

C. A clustering algorithm.

D. A post-processing step.

- **Correct Answer: B**

- **التفسير:** وتقول "الحته دي احتمال يكون فيها جسم" وتحدد أبعاده Features دي شبكة صغيرة بتعدي على الـ المبدئية.

28. What are "Anchor Boxes" in Faster R-CNN?

A. Heavy weights to keep the model stable.

B. Pre-defined boxes of different scales and aspect ratios used as reference for predicting bounding boxes.

C. Boxes that anchor the image to the screen.

D. The final output boxes.

- **Correct Answer: B**

- **التفسير:** دي مربعات بمقاسات ثابتة (طويل، عريض، صغير) الشبكة بتجربها في كل مكان عشان تشوف الجسم. راكب على مين فيهم.

29. Fast R-CNN uses a multi-task loss function to train:

A. Only the classifier.

B. Only the regressor.

C. Both the classifier and the bounding box regressor jointly.

D. The Selective Search algorithm.

- **Correct Answer: C**

- ويضبط أبعاد المربع (Classifier) الموديل ليتعلم حاجتين في نفس الوقت: يعرف نوع الجسم: **التفسير** (Regressor).

30. The speed of Faster R-CNN allows it to run at:

A. 1 frame per minute.

B. Near real-time frame rates (e.g., 5-17 FPS depending on backend).

C. 1000 FPS.

D. It is slower than R-CNN.

- **Correct Answer: B**

- ، السرعة زادت جداً وبقت تنفع للفيديوهات (End-to-End) بسبب إن كل حاجة بقت جوه الشبكة: **التفسير**.

Section 7: Segmentation (Mask R-CNN)

31. What is the goal of Instance Segmentation?

A. Label every pixel with a class (e.g., sky, road).

B. Detect objects and color every pixel of each distinct object instance.

C. Just draw boxes.

D. Compress the image.

- **Correct Answer: B**

- (Pixel-level) مش بس بنعرف إن في "ناس" في الصورة، ده إحنا بنلون كل "شخص" بلون لوحده بدقة: **التفسير**.

32. Mask R-CNN extends Faster R-CNN by adding:

A. A branch for predicting the binary mask of the object.

B. A second CNN.

C. A depth sensor.

D. Audio processing.

- **Correct Answer: A**

- (الشكل الدقيق للجسم) Mask ، وظيفته يطلع الـ Box والـ Class زودوا فرع تالت جنب الـ: **التفسير**.

33. What problem in RoI Pooling does "RoIAlign" solve?

A. It makes it faster.

B. It fixes the misalignment caused by quantization (rounding coordinates), which hurts pixel-level accuracy.

C. It reduces memory usage.

D. It removes the background.

- **Correct Answer: B**

- يستخدم RoIAlign وده بيبوظ الدقة في التحديد، الـ (Rounding) كانت بتقرب الأرقام RoI Pooling الـ: **التفسير** interpolation. عشان تحافظ على المكان بالطبط interpolation

34. The output of the mask branch in Mask R-CNN is:

A. A standard RGB image.

B. A binary mask (matrix of 0s and 1s) for the object.

C. A text description.

D. A single integer.

- **Correct Answer: B**

- الخرج بيكون صورة أبيض وأسود، الأبيض (1) هو جسم الكائن، والأسود (0) هو الخلفية: **التفسير**

35. Mask R-CNN is typically built on top of which backbone architecture?

A. LeNet.

B. ResNet (often with Feature Pyramid Network).

C. Only VGG.

D. A simple MLP.

- **Correct Answer: B**

- لأنها قوية جداً في استخراج الميزات (Backbone) كعمود فقري ResNet غالباً بيستخدموا: **التفسير**

Section 8: Miscellaneous & Technical Details

36. A 1×1 convolution layer with D input channels and K filters requires how many parameters (ignoring bias)?

A. $D \times K$

B. $D + K$

C. 1

D. $3 \times 3 \times D \times K$

- **Correct Answer: A**

- 1×1 فلتر، يبقى المجموع $1 \times K$ ، ومعانا $1 \times D$ كل فلتر حجمه 1 : **التفسير**
 $D \times K = D \times K$.

37. Which architecture introduced the concept of "Auxiliary Classifiers"?

A. VGGNet.

B. GoogLeNet (Inception).

C. ResNet.

D. AlexNet.

- **Correct Answer: B**

- Gradient. جوجل نت استخدمتها عشان تدريب الشبكة العميقة وتمشية الـ:التفسير

38. Why do modern architectures often replace Fully Connected layers with Global Average Pooling?

- A. To increase parameter count.
- B. To reduce the massive number of parameters and allow variable input sizes.
- C. To make the network slower.
- D. Because FC layers are impossible to implement.

- **Correct Answer: B**

- بيطلع نفس النتيجة تقريباً من غير أي أوزان زيادة Pooling بتاخذ مساحة رهيبة، الـ FC الـ:التفسير

39. Transfer learning works best when:

- A. The source dataset is small.
- B. The target dataset is small, and we use a model pre-trained on a large dataset (like ImageNet).
- C. We train everything from scratch.
- D. The domains are completely unrelated.

- **Correct Answer: B**

- النقل مفيد جداً لما يكون معاك داتا قليلة، فبتستخدم "خبرة" موديل كبير شاف ملايين الصور قبل كده:التفسير
[Updating slide].

40. What is "Transfer Learning"?

- A. Moving data from one computer to another.
- B. Taking a model trained on one task/dataset and re-purposing it for another related task.
- C. Translating text.
- D. Training two models at once.

- **Correct Answer: B**

- [Slide 5 update]. إعادة استخدام "نكاء" الموديل في مهمة جديدة بدل ما نبدأ من الصفر:التفسير

41. In VGG16, the image size is halved (downsampled) how many times?

- A. 2 times.
- B. 5 times (due to 5 max-pooling layers).
- C. 10 times.
- D. Never.

- **Correct Answer: B**

- ، كل واحدة بتقسم الحجم على 2، فالصورة بتصغر $5^2 = 32$ مرة Max Pooling في 5 طبقات:التفسير

42. What is a "bottleneck" layer in ResNet?

- A. A layer that stops training.
- B. A design using 1×1 convs to reduce dimensions before 3×3 conv, then restore them, to save computation.
- C. The output layer.
- D. A pooling layer.

- **Correct Answer: B**

- Bottleneck العميقة (زي 101/50)، يستخدموا تكتيك الـ ResNet في الـ: التفسير 1×1 to 3×3 to 1×1 [20, implicitly].

43. Fully Convolutional Networks (FCNs) are primarily used for:

- A. Classification only.
- B. Semantic Segmentation (predicting a class for every pixel).
- C. Audio recognition.
- D. Reinforcement learning.

- **Correct Answer: B**

- (Heatmap) "عشان تطلع خريطة Convolution لـ Classification layers بتحول الـ FCN الـ: التفسير Segmentation بدل رقم واحد، وده أساس الـ

44. What does "End-to-End" training mean in the context of Faster R-CNN?

- A. We train each part separately.
- B. We train the whole system (RPN + Classifier + Regressor) at once with a combined loss function.
- C. We only train the last layer.
- D. We train on CPUs only.

- **Correct Answer: B**

- يعني الشبكة كلها حته واحدة، بتدخل الصورة من ناحية وتطلع النتيجة من الناحية الثانية، والـ: التفسير Backpropagation بيضبط كل الأجزاء مع بعض

45. What happens if you remove skip connections from a very deep ResNet?

- A. It becomes a VGG-like network and likely suffers from optimization issues (high training error).
- B. It works better.
- C. It becomes a DenseNet.
- D. Nothing changes.

- **Correct Answer: A**

- وهيبقى صعب جداً تدريبها Gradient ، الشبكة هتفقد ميزة تدفق الـ Skip connections من غير الـ:التفسير .وهتغطي نتائج أسوأ

46. Which network introduced the "Depthwise Separable Convolution"?

A. ResNet. B. MobileNet. C. VGG. D. AlexNet.

- **Correct Answer: B**

- عشان تكون خفيفة وسريعة MobileNet دي العلامة المسجلة لـ:التفسير .

47. In the context of CNNs, what does "Manifold" refer to?

A. The exhaust pipe of a car.
B. The lower-dimensional structure/space where meaningful data lies (embedded features).
C. The training loss curve. D. The raw pixel space.

- **Correct Answer: B**

- ده الفضاء "المضغوط" اللي الموديل بيحط فيه الصور المتشابهة جنب بعض، بعيداً عن دوشة البيكسلات :التفسير .

48. Why did ResNet win the ILSVRC 2015 challenge?

A. It had the most parameters.
B. It successfully trained an ultra-deep network (152 layers) using residual learning.
C. It used the largest images. D. It was trained on video.

- **Correct Answer: B**

- Residual Blocks الفوز كان بسبب القدرة على تدريب شبكة عمقها خيالي (وقتها) بفضل فكرة الـ:التفسير .

49. The "classification head" of a standard detection model (like Fast R-CNN) usually outputs:

A. Probability distribution over classes (Softmax). B. An image.
C. Audio. D. Binary code.

- **Correct Answer: A**

- رأس التصنيف بيطلع احتمالات (ده قطة بنسبة 90%، كلب 10%..):التفسير .

50. The "regression head" of a detection model outputs:

- A. Class labels. B. 4 coordinates (x, y, width, height) to adjust the bounding box position.
C. Pixel colors. D. Nothing.

• **Correct Answer: B**

- **التفسير** (\$dx, dy, dw, dh\$) وظيفته "يظبط" مقاسات المربع عشان يجي على الجسم بالظبط Regression رأس الـ: **التفسير** (\$dx, dy, dw, dh\$).

شرح مفصل:

(Modern ConvNets) إلى الشبكات العصبية الحديثة (مثل AlexNet) ننتقل من الأساسيات (Lecture 6) أهلاً بك. في هذه المحاضرة التي غيرت شكل المجال، وناقش كيف تم حل مشاكل العمق والسرعة (Modern ConvNets).

:إليك شرح مفصل لكل جزء في المحاضرة باللهجة المصرية البسيطة

1. مفهوم التضمين (Embeddings)

- ، يعني حوالي 150 ألف $224 \times 224 \times 3$ تخيل أن لديك صورة حجمها كبير جداً: **الفكرة** هذه الأرقام الكثيرة (Dimensionality Reduction) "الشبكة العصبية تقوم بعملية "ضغط" أو "تلخيص". (رقم AlexNet) أو 4096 في ResNet مثلاً 2048 رقم في) لتحويلها إلى فيكتور صغير
- "هي بتمثل" المعنى **Embedding** أو **Latent Representation** **ليه بنعمل كدة؟** الأرقام القليلة دي بنسميها الحقيقي للصورة (زي إن فيها كلب أو قطة) وبترمي التفاصيل اللي مالهاش لازمة زي لون (Semantics) الخلفية أو مكان الجسم بالظبط
- كل ما تدخل أعمق في الشبكة، كل ما الفلاتر تتعلم حاجات أعقد. أول طبقة بتشوف خطوط وألوان، **:الطبقات** الطبقات اللي بعدها بتشوف أشكال، وفي الآخر بتشوف أجسام كاملة

2. ثورة العمق والبساطة VGGNet شبكة

- الفلسفة بتاعتها كانت: "خلينا نبسط الفلاتر بس نزود ImageNet ظهرت سنة 2014 وكانت الوصيف في مسابقة
- بس في كل الشبكة 3×3 قررنا نستخدموا فلاتر صغيرة جداً بحجم 3×3 سر الـ 3×3
- ؟ 7×7 أو 5×5 أحسن من 5×3 ليه 3×3
 1. بتاع (Receptive Field) "فوق بعض، هيدوك نفس" مجال الرؤية 3×3 لو حطيت طبقتين 3×3 7×7 ولو حطيت 3 طبقات، هيدوك نفس الـ 5×5 فلتير واحد 5×5
 2. عدد الباراميترز (الأوزان) هيكون أقل، والحسابات أسرع: **الميزة**

3. فده بيخلي الشبكة "أذكى" (ReLU زي Non-linearity) بين كل طبقة وطبقة بنحط دالة تنشيط: الأهم .وتقدر تفهم حاجات أعقد

3. شبكة GoogLeNet (Inception Module)

- 3×3 ولا $1 \times 3 \times 3$ الموديل ده حب يحل مشكلة: "أنا مش عارف أختار فلتر مقاسه كام.. هل 1×1 ولا 5×5 ؟".
- إقالك شغلهم كلهم مع بعض بالتوازي في نفس الطبقة: (Inception Module) الحل
- كثرة الفلاتر دي خلت الحسابات ثقيلة جداً: المشكلة
- قبل الفلاتر الكبيرة عشان 1×1 استخدموا فلاتر 1×1 : (Convolution 1×1) الحل العبقري لأنها بتخفف الحمل الحسابي "Bottleneck" ويضغطوا الداتا. دي سموها (Dimensions) يقللوا عدد القنوات جداً.
- عشان الشبكة كانت طويلة (22 طبقة)، الإشارة كانت بتضعف وهي راجعة Auxiliary Classifiers: فقاموا عملوا "مخارج فرعية" في نص الشبكة تحسب الخطأ وتساعد في توصيل الـ (Vanishing Gradient). للطبقات الأولى Gradient

4. (الحل الجذري للشبكات العميقة) ResNet شبكة

- وصلت لـ ResNet دي أهم شبكة فيهم (سنة 2015). قبلها كان صعب ندرّب شبكات أعمق من 20 طبقة، لكن 152 طبقة وأكثر.
- لكن لأن الشبكة Overfitting اكتشفوا إن لما بيزودوا الطبقات، نسبة الخطأ بتزيد! وده مش بسبب الـ: المشكلة (Vanishing Gradient) والإشارة بتضيع (Optimization issue) مش عارفة تتعلم
- الحل (Residual Block & Skip Connections):
 - يعدي من فوق الطبقات وينجمع على الخرج x بيخلي الدخل (Shortcut) "عملوا" كوبري
 - المعادلة بقت: $H(x) = F(x) + x$.
 - $F(x)$ بس. ولو الطبقة دي مالهاش لازمة، الشبكة هتخلي الـ (Residual) "ده خلى الشبكة تتعلم" الفرق ، فبقى سهل جداً ندرّب شبكات عميقة جداً من غير ما الأداء يقع (x) بصفر، والداتا هتعيدي زي ما هي

5. شبكات أخرى (Variations)

- ResNeXt: Inception زي (Cardinality) بتفصل المسارات ResNet نسخة محسنة من

- **DenseNet:** هنا كل طبقة تتوصل بكل الطبقات اللي وراها. كل واحد بياخد "خبرة" اللي قبله كله. ده بيخلي تدفق المعلومات قوي جداً ويقلل عدد الباراميترز.
- **MobileNet:** Depthwise Separable معمولة مخصوص للموبايلات. بتستخدم حيلة اسمها Convolution (بتفصل التعديل المكاني عن تعديل القنوات)، وده بيخليها سريعة جداً وخفيفة.
- **BagNet:** (Shape) أكثر من شكله (Texture) غالباً بتهتم بـ "لمس" الشيء CNNs بحث غريب أثبت إن الـ BagNet (يعني لو وريتها "جلد فيل" على شكل "قطة"، ممكن تقولك ده فيل).

6. اكتشاف الأجسام (Object Detection)

إزاي نحدد مكان الجسم ونرسم مربع حوله؟ التطور مشي كالتالي:

1. R-CNN (الأب الروحي - بطيء جداً):

- عشان تقترح 2000 مربع في الصورة (Selective Search) بيستخدم خوارزمية خارجية.
- لوحده CNN بياخد كل مربع، يقصه، ويدخله على.
- ألفين مرة للصورة الواحدة CNN بطيء جداً لأنك بتشتغل الـ العيب.

2. Fast R-CNN (أسرع شوية):

- CNN الحل: ندخل الصورة كلها مرة واحدة على الـ.
- RoI ونقص منها الحنت اللي عايزينها باستخدام تقنية اسمها (Feature Map) بعدين ناخذ الميزات Pooling.
- Selective Search بتشتغل مرة واحدة بس. بس لسه بنعتمد على الـ CNN بقت أسرع بكثير لأن الـ الخارجي البطيء عشان الاقتراحات.

3. Faster R-CNN (السرّيع والذكي):

- خالص Selective Search لغى الـ.
- هي اللي بتقترح Region Proposal Network (RPN) عمل شبكة صغيرة جوه الموديل اسمها (Anchor Boxes بناءً على) الأماكن المهمة.
- (Real-time) (حتى واحدة بتتعلم مع بعض)، وبقت سريعة جداً End-to-End الموضوع كله بقى.

7. التجزئة (Segmentation)

• Mask R-CNN:

- عايزين نحدد الجسم بالبكسل مش بس بمربع.

- صورة أبيض وأسود بتحدد شكل (Binary Mask) يطلع Faster R-CNN زودوا فرع ثالث على (الجسم).
 - **RoIAlign:** وده بيبوظ الدقة في (Rounding) القديم كان بيقرب الأرقام RoI Pooling اكتشفوا إن الـ RoIAlign تحديد الحواف. الـ حل المشكلة دي وبقي دقيق جداً
- **Fully Convolutional Networks (FCN):**
 - ، فبقت الشبكة تطلع "خريطة 1×1 لفلاتر (Fully Connected) حولوا الطبقات الأخيرة Segmentation بدل تصنيف واحد، وده أساس شغل الـ (Heatmap) "حرارية